



北京邮电大学

硕士研究生学位论文开题报告

学 号： 2024140690

姓 名： 张芷宁

学 生 类 别： 专硕(全日)

学 院： 计算机学院（国家示范性软件学院）

学 科 / 专 业 (代 码)： 计算机技术(085404)

研 究 方 向： 物联网、多媒体技术与嵌入式技术

导 师 姓 名： 刘亮

攻 读 学 位： 电子信息硕士

2025 年 11 月 23 日

论文题目	基于多模态大模型的车路协同车辆轨迹预测方法研究与实现		
选题来源	国家自然科学基金项目	论文类型	应用研究
开题日期	2025-11-23	开题地点	教三 623
课程名称	学分	成绩	班级排名
有效沟通技巧 (MOOC)	1.0	99	共 (2500) 人, 排第 (199) 名
工程伦理 (MOOC)	2.0	70	共 (140) 人, 排第 (130) 名
高级操作系统	2.0	87	共 (212) 人, 排第 (69) 名
高级数理逻辑	3.0	76	共 (269) 人, 排第 (152) 名
计算机通信新技术 (系列讲座)	2.0	89	共 (194) 人, 排第 (27) 名
高级分布式系统	2.0	81	共 (211) 人, 排第 (84) 名
计算机网络前沿技术与应用	2.0	89	共 (164) 人, 排第 (13) 名
智慧交通与自动驾驶	2.0	89	共 (202) 人, 排第 (194) 名
快应用与语音识别技术融合实践	2.0	90	共 (21) 人, 排第 (3) 名
自然辩证法概论	1.0	84	共 (109) 人, 排第 (104) 名
研究生英语国际学术交流	2.0	85	共 (28) 人, 排第 (14) 名
新时代中国特色社会主义思想理论与实践	2.0	83	共 (110) 人, 排第 (72) 名
图论及其应用	3.0	90	共 (189) 人, 排第 (47) 名
网络管理原理	2.0	87	共 (61) 人, 排第 (37) 名

已修课程是否满足培养方案要求： 否

修课计划：继续完成科研诚信与学术规范课程

一、立题依据（包括研究目的、意义、国内外研究现状和发展趋势，需结合科学研究发展趋势来论述科学意义；或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录）（不少于 800 字）

1. 研究目的及意义

近年来，随着深度学习与多模态感知技术的演进，自动驾驶领域取得了显著进展。自动驾驶系统通过车载传感系统感知道路环境，自动控制车辆的转向和速度，使车辆能够安全、可靠地行驶。其核心任务在于精准感知周围环境，预测交通参与者的未来状态，并利用这些信息规划出安全、高效的行驶轨迹，以指导自动驾驶车辆的决策与控制。但传统的单车智能方案受限于车载传感器的物理视场与感知距离，在应对城市复杂路口、强遮挡区域时存在天然物理盲区，难以满足高安全性的决策需求，易导致规划出次优甚至危险轨迹。车路协同（Vehicle-to-Everything, V2X）技术通过引入路侧传感器（如摄像头、LiDAR），利用其高位俯视视角覆盖车端盲区，提供了更为全局的感知信息，有效拓展了车辆的感知边界。

然而，如何高效利用路侧信息是当前 V2X 方案面临的关键难题。一方面，受限于车路通信带宽的物理瓶颈，传输原始路侧感知数据会产生高时延，难以满足实时性要求。另一方面，车端平视视角与路侧俯视视角存在巨大视域差异，导致数据在空间结构上错位，且提取出的视觉特征分布存在显著差异，使得跨视域几何特征的融合困难重重。与此同时，主流轨迹预测算法多侧重于几何特征的数值回归，缺乏对深层交通语义的认知推理能力。这导致模型在复杂场景中无法像人类驾驶员一样结合常识进行因果判断，预测准确率和泛化性不足。

多模态大模型（Multimodal Large Language Models）的出现为解决上述问题提供了新思路。此类模型具备强大的语义理解能力，能够将视觉特征映射至高维的语义空间，并利用其内建的思维链（Chain-of-Thought, CoT）推理能力，实现“感知-认知-决策”的闭环。因此，本课题旨在将多模态大模型引入车路协同技术，通过设计面向带宽受限的跨视域协同感知方法，实现路侧关键信息的低带宽高效传输与车路异构特征的深度融合；并利用跨模态场景语义映射与思维链推理策略，帮助大模型建立从视觉特征到深层交通语义的隐式映射，增强大模型对复杂场景因果推理能力，并输出兼具安全性与可解释性的精准轨迹。基于上述方法，我们旨在设计并实现一个基于多模态大模型的车路协同感知与决策原型系统，并对其进行实验评估。

本课题的研究意义在于突破现有车路协同面临的带宽受限与视域异构的物理瓶颈，推动促进车路协同技术从物理层面的数据联通向语义层面的特征融合发展。针对车路跨视域特征对齐困难以及传统模型缺乏因果推理能力的痛点，本研究通过构建基于跨视域感知与跨模态语义映射的多模态大模型轨迹预测框架。一方面，实现了低成本、高精度的车路感知融合，有效拓展了单车的感知边界；另一方面，赋予了模型在复杂场景下类人的推理能力，显著提升了轨迹预测的准确性与鲁棒性，并增强了模型决策的可解释性，为车路协同系统的智能化发展提供一定的理论参考与技术积累。

2. 国内外研究现状与发展趋势

针对本课题的研究内容，本节将从单车自动驾驶与车路协同的感知与规划、多模态大模型方法、以及多模态大模型在自动驾驶、车路协同场景下的应用这三个方面展开论述。

在自动驾驶感知方法的演进中，为了提升单车智能在多视角下的感知能力，基于鸟瞰图（BEV）的视觉感知方法逐渐成为主流。早期的 BEV 方法（如 BEVDet[1]、BEVFormer[2]）主要采用 2D 到 3D 的技术路线，将多个视角的图像特征投影到稠密的 3D BEV 空间以实现目标检测。然而，这种从稠密特征到稠密特征的转换计算量巨大，且在车端有限算力下难以平衡感知范围与高分辨率精度的矛盾。为此，以 DETR3D[3]和 PETR[4]为代表的稀疏感知策略（Sparse Perception）作为一种高效的改进方法被提出，其关键思想是不生成显式的稠密 BEV 特征，而是构造 3D 空间下的稀疏查询向量，直接聚合不同视角的特征并输出检测结果。这种稀疏实例化的表征方式不仅计算效率更高，更在端到端自动驾驶中发挥了核心作用。典型的端到端模型 UniAD[5]正是利用了这一方法，通过在模块间传递稀疏的实例级特征，实现了从感知到规控的联合优化。此外，稀疏感知方法在实现视觉与 LiDAR 的高效融合方面也展现出巨大的潜力。针对纯视觉深度估计不准的问题，BEVDepth[6]创新性地引入稀疏 LiDAR 点云作为显式的深度监督信号，有效提升了视觉感知的精度。

然而，即便单车感知算法在特征稀疏化与端到端架构上取得了显著突破，其感知仅依赖车载传感器，往往受限于视场角（FoV）和物理遮挡，难以在复杂动态环境中确保可靠的情境感知。相比之下，V2X 协同感知通过共享车辆与基础设施的传感信息，能够构建对交通环境更全面的理解；特别是在高遮挡场景下，外部视角能有效补偿盲区，显著提升安全关键决策的可靠性。现有的协作方法根据融合层级主要分为早期、后期和中间融合。早期融合直接传输原始传感器数据（如激光雷达点云或相机图像）[7][8]，虽能实现最优的性能，但其对通信带宽的需求极高；而后期融合仅交互感知后的高层级信息[9][10]（如 3D 检测框），虽节省了带宽但易丢失环境特征导致精度受限，难以有效利用多视角互补优势。相比之下，中间融合通过传输通过传输提取后的深度特征图或压缩表征，在感知精度与通信负载间取得平衡，成为当前主流方向。针对特征融合中的视域异构性问题，V2X-ViT[11]提出了一种基于视觉 Transformer 的统一框架，利用多尺度窗口注意力机制自适应融合车路异构特征以应对定位误差。针对通信带宽受限问题，UniV2X[12]设计了“稀疏-密集”混合传输机制，借鉴 UniAD[5]的方法，通过仅传输关键的实例级查询和场景级占用图，这些传输对象本质上属于保留了高维间层隐式特征，从而在低带宽条件下实现了端到端的高效规划。




图 1：车路协同感知规划系统架构

随着大语言模型（LLM）展现出的通用推理能力，视觉语言模型（VLM）作为连接感知与认知的桥梁，在通用视觉任务中展现了应用潜力。其核心在于如何将图像、点云等异构模态特征映射到统一的语言特征空间以实现语义对齐。在通用 2D 领域，LLaVA[13]通过线性投影层（Linear Projection）将 CLIP 提取的视觉特征转化为语言 Token，并利用指令微调实现了图文对齐。而在 3D 感知领域，LiDAR 点云与视觉、语言的模态对齐也取得了进展。Point-LLM[14] 和 Point-Bind[15]提出了构建 3D 点云与文本、图像的联合嵌入空间（Joint Embedding Space）。它们通过对比学习机制，使点云编码器的几何特征与预训练编码器的语义特征在潜在空间中对齐，从而让 LLM 能够直接理解稀疏、无序的 LiDAR 数据，无需依赖大量 3D 指令标注。




图 2：VLM 模型（LLaVA）网络结构

近年来，单车自动驾驶大模型正从单纯的感知工具向决策中心演进。得益于视觉语言模型（VLM）在常识知识储备、逻辑推理及可解释性方面的天然优势，其有效弥补了传统端到端（E2E）模型“黑盒”决策的局限，成为提升单车自动驾驶系统智能化的重要途径。近年来的研究探索了多种利用 VLM 增强驾驶任务的方法。在感知与规划的直接映射方面，Drive-with-

LLMs[16]通过 Transformer 网络将真值感知数据编码为潜在空间 (Latent Space)，进而利用大语言模型预测未来轨迹；DriveGPT4[17]则直接处理前视视频流，在生成规划控制信号的同时，能够提供自然语言形式的决策解释，显著增强了系统的透明度。在模型架构的融合创新方面，DriveVLM[18]首创性地将 VLM 与传统 E2E 模型无缝集成，形成“快慢系统”，由 VLM 预测低频轨迹与决策意图，再由 E2E 模型进行高频轨迹细化；而 Senna[19]则避开了 VLM 不擅长的精确数值预测，专注于生成自然语言形式的高层规划决策，简化了决策流程。此外，在训练与验证范式上，DriveMLM[20]验证了基于 VLM 的规划在闭环仿真环境中的有效性，而 ELM[21]则引入了跨域视频数据的 VLM 大规模预训练，证明了多样化数据源对提升驾驶性能的关键作用。





图 3：单车自动驾驶 VLM 系统中的思维链推理流程

将 VLM 引入 V2X 领域以解决异构数据融合与语义推理问题是当前的前沿趋势。针对传统 V2X 融合缺乏语义建模的问题，V2X-VLM[22]框架首次利用大型 VLM 作为骨干网络，通过对比学习将车端与路端的异构视觉数据与结构化文本提示 (Text Prompts) 进行特征对齐，实现了更鲁棒的协同轨迹规划。为了满足边缘侧实时性需求，REACT[22]框架则提出了一种轻量化方案，利用路侧单元发送的事故警报作为文本引导，结合车载 BEV 图像，通过残差轨迹融合 (Residual Trajectory Fusion) 策略引导 VLM 生成避撞轨迹。这些研究表明，利用大模型作为语义桥梁，是实现车路协同从数据级互联向语义级认知跃迁的关键路径。



- [8]. Arnold E, Dianati M, de Temple R, et al. Cooperative perception for 3D object detection in driving scenarios using infrastructure sensors[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 23(3): 1852-1864.
- [9]. Rauch A, Klanner F, Rasshofer R, et al. Car2x-based perception in a high-level fusion architecture for cooperative perception systems[C]//2012 IEEE Intelligent Vehicles Symposium. IEEE, 2012: 270-275.
- [10]. Rawashdeh Z Y, Wang Z. Collaborative automated driving: A machine learning-based method to enhance the accuracy of shared information[C]//2018 21st International Conference on Intelligent Transportation Systems (ITSC). IEEE, 2018: 3961-3966.
- [11]. Xu R, Xiang H, Tu Z, et al. V2x-vit: Vehicle-to-everything cooperative perception with vision transformer[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2022: 107-124.
- [12]. Yu H, Yang W, Zhong J, et al. End-to-end autonomous driving through v2x cooperation[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(9): 9598-9606.
- [13]. Liu H, Li C, Wu Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2023, 36: 34892-34916.
- [14]. Xu R, Wang X, Wang T, et al. Pointllm: Empowering large language models to understand point clouds[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 131-147.
- [15]. Guo Z, Zhang R, Zhu X, et al. Point-bind & point-llm: Aligning point cloud with multi-modality for 3d understanding, generation, and instruction following[J]. arXiv preprint arXiv:2309.00615, 2023.
- [16]. Chen L, Sinavski O, Hünemann J, et al. Driving with llms: Fusing object-level vector modality for explainable autonomous driving[C]//2024 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2024: 14093-14100.
- [17]. Xu Z, Zhang Y, Xie E, et al. Drivegpt4: Interpretable end-to-end autonomous driving via large language model[J]. IEEE Robotics and Automation Letters, 2024.
- [18]. Tian X, Gu J, Li B, et al. Drivevllm: The convergence of autonomous driving and large vision-language models[J]. arXiv preprint arXiv:2402.12289, 2024.
- [19]. Jiang B, Chen S, Liao B, et al. Senna: Bridging large vision-language models and end-to-end

- autonomous driving[J]. arXiv preprint arXiv:2410.22313, 2024.
- [20]. Wang W, Xie J, Hu C Y, et al. Drivemlm: Aligning multi-modal large language models with behavioral planning states for autonomous driving[J]. arXiv preprint arXiv:2312.09245, 2023.
- [21]. Zhou Y, Huang L, Bu Q, et al. Embodied understanding of driving scenarios[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 129-148.
- [22]. You J, Shi H, Jiang Z, et al. V2x-vlm: End-to-end v2x cooperative autonomous driving through large vision-language models[J]. arXiv preprint arXiv:2408.09251, 2024.
- [23]. Yang F, Yu B, Zhou Y, et al. Edge-Based Multimodal Sensor Data Fusion with Vision Language Models (VLMs) for Real-time Autonomous Vehicle Accident Avoidance[J]. arXiv preprint arXiv:2508.01057, 2025.

二、研究内容和目标（说明课题的具体研究内容，研究目标和效果，以及拟解决的关键科学问题。此部分为重点阐述内容）（不少于 2500 字）

1. 研究内容概述：

针对车路协同中存在的通信带宽受限、跨视域特征异构导致的融合难题，与传统模型缺乏因果推理能力的痛点，本课题拟构建一套基于多模态大模型的车路协同车辆轨迹预测方法。研究内容将围绕两个核心方法展开：首先，研究面向带宽受限的跨视域协同感知方法，探究如何在有限带宽下高效传输路侧信息，并将其与车端视角进行空间几何映射与重构，从而为模型提供跨视域视觉表征。其次，研究基于场景语义映射的大模型推理与轨迹规划方法，建立从视觉特征到深层交通语义的隐式映射机制；解决大模型难以理解几何约束的问题；并利用大模型的逻辑推理能力将感知信息转化为可解释的因果链条，进而自回归生成兼具安全性、准确性与可解释性的车辆轨迹。

1.1. 面向带宽受限的跨视域协同感知方法

在带宽限制下，为在保留高价值视觉信息与减少数据传输冗余之间寻求最优平衡，本课题的第一个研究内容拟提出一种基于“稀疏感知-视觉重构”的非对称协同感知机制，具体实现方法如下：




图 5：面向带宽受限的跨视域协同感知方法

首先，针对车端感知缺乏长时序记忆且易受通信抖动影响的痛点，研究基于历史状态交互的自适应鲁棒感知方法。鉴于现有端到端模型对短时序输入的依赖导致在动态遮挡或通信丢包时易发生感知中断，本研究将利用自车感知的稳定性，并引入历史时序特征对当前感知进行增强。具体而言，通过构建时序记忆机制，存储与检索自车历史轨迹与运动趋势，进而生成包含自车意图与局部环境动态的高鲁棒性状态表征。该方法旨在确保即便在外部通信链路不稳定的极端条件下，车端系统仍能维持高频、稳定的基础规划能力，并为后续大模型推理提供连续的自车状态提示。

其次, 针对路侧原始数据传输高延迟与后期融合信息丢失的矛盾, 构建基于深度引导的稀疏感知框架。在实际场景中, 传输原始图像或点云会导致数百毫秒的延迟, 而仅传输检测结果 (如边界框) 又会导致环境背景与长尾物体信息的严重丢失, 使得车端大模型无法进行深度推理。为此, 我们设计了基于 LiDAR 深度引导的多模态融合网络, 将 2D 图像特征精准提升至 3D BEV 空间。在此基础上, 利用路侧高位俯瞰优势, 将全域感知信息解耦为静态拓扑(Map Queries)与动态实例(Agent Queries)两类特征。这两类 Query 本质上是对物理空间的稀疏矢量化重构, 既保留了环境的隐式特征细节, 又实现了极低带宽占用。

最后, 针对不同视角特征难以直观对齐与交互的难题, 研究基于跨视域映射的视觉提示重构与协同感知机制。为了实现车路信息的高效融合与大模型的可解释性推理, 本部分重点研究如何将路侧传输的稀疏几何向量精准映射至车端视角, 并将其转化为大模型可理解的视觉提示信号。通过建立视觉重构模块, 在自车感知底图上叠加重构的视觉提示, 生成路侧增强的融合视觉表征。以此作为多模态大模型的直接输入, 引导模型利用注意力机制直观识别盲区风险, 从而生成兼具安全性与可解释性的驾驶决策。

1.2 基于场景语义映射的大模型认知决策与轨迹生成方法

与视觉信息相对, 文本信息在多模态大模型(VLM)的架构体系中起着理解与推理的关键桥梁作用。自然语言作为一种高度压缩且具备符号化特性的信息载体, 拥有显式编码交通法规、事故因果关系以及博弈交互意图等抽象概念的独特能力, 而这些逻辑信息往往难以在像素级的视觉空间中有效解耦。然而, 这种强大的认知推理潜力在现有的车辆-路侧协同(VICAD)系统中并未得到有效释放, 根本原因在于, 大模型难以理解路侧固定视角与车端运动视角之间的视域关联, 导致无法从路侧图像中有效提取对自车规划有用的空间几何信息。在传统的协同方案中, 往往直接将路侧原始图像传输给车端。然而, 现有的视觉语言模型(VLM)缺乏对 V2X 复杂空间映射的先验知识, 难以理解路侧视角下的像素特征与自车行驶路径之间的几何相关性。面对路侧传输的图像, 模型往往“视而不见”, 无法识别自车在路段视角下的位置, 难以理解复杂的车道结构, 更无法感知宏观的交通态势(如拥堵情况、信号灯、天气等影响)。这种“视觉-语义”认知鸿沟, 使得大模型难以在感知特征与预测轨迹之间建立稳固的逻辑因果链, 最终导致系统在面对长尾复杂场景时, 生成的决策缺乏依据, 轨迹缺乏可解释性。

针对上述问题, 本课题第二个研究内容提出一种基于场景语义映射的大模型推理框架。我们认为, 要让大模型真正“读懂”路侧信息, 必须在训练阶段引入显式的语言描述作为引导。因而需要设计一套专属于 V2X 场景的文本提示机制。具体而言, 我们首先对上游获取的稀疏结构化表征进行语义序列化处理, 将几何约束(如车道拓扑、物体坐标)解析为大模型可直接理解的结构化文本描述(如“车道 L2 连接至路口区域”)。同时引入视觉语言模型对路侧感知的深层环境信息(如宏观车流量、天气状况、信号灯倒计时)生成场景级深度描述。这些描述并不作为推理时的输入, 而是作为一种特权监督信号(Privileged Supervision Signal)参与训练, 在微调过程中, 我们将这些文本与路侧增强的融合视觉特征进行多模态对齐, 引导大模型学习视觉提示符号与深层环境语义

之间的对应关系。通过这种方式，大模型学会了如何从视觉符号中挖掘出隐含的几何约束与环境态势。

在此基础上，我们构建“感知-认知-规划”的思维闭环，具体而言，大模型首先基于视觉提示与自车状态，通过思维链进行场景级认知推理，生成包含风险评估与决策意图的显式语言指令(如“前方车辆减速，准备向左变道”);随后，模型进一步激活轨迹生成决策，将连续的物理驾驶空间离散化为特殊的动作坐标 **Token**。在这一阶段，大模型利用其自回归生成能力，直接逐点预测未来的行驶轨迹路点。通过这种方式，我们实现了从环境理解到决策推理，再到精准轨迹输出的完整闭环，使系统不仅能生成安全的轨迹，还能提供“所想即所行”的可解释性依据。

2. 研究目标和效果

本课题的主要研究目标是突破传统车路协同技术在通信带宽、视域异构及认知推理方面的局限，构建一套兼具低通信负载、高感知精度与强可解释性的面向车路协同的多模态大模型自动驾驶系统。具体目标包括：

- 1) 构建基于稀疏查询的跨视域协同感知机制，旨在突破通信带宽瓶颈，实现路侧全域几何信息与车端视角的低延迟、零失真精准对齐。
- 2) 建立基于场景语义映射与思维链闭环的认知决策框架，旨在填补几何-语义鸿沟，赋予系统类人的因果推理能力与“所想即所行”的可解释轨迹生成能力。
- 3) 搭建基于多模态大模型的车路协同自动驾驶原型系统，旨在通过复杂长尾场景的全链路测试，验证所提方法在提升系统鲁棒性与安全性方面的有效性。

通过这些研究目标，我们将验证所提出的协同感知与规划方法的有效性。预期效果包括：在 V2X 通信带宽受限的条件下，仍能保持高精度的轨迹预测能力，显著降低因时空错位导致的感知误差。在复杂驾驶场景下，模型能够生成符合交通法规且具备因果解释的安全轨迹，提升车路协同系统的智能化水平与决策透明度。

3. 拟解决的关键科学问题

- 1) 车路协同系统中带宽受限与异构视域特征融合问题

在车路协同系统中，核心问题在于路侧海量感知数据的高维冗余性与车路通信链路的带宽受限性之间的矛盾，以及路侧俯视与车端平视之间存在的视域异构性。路侧传感器虽然视野广阔，但海量的原始数据（高分辨率图像、密集点云）在受限的 V2X 带宽下无法实时全量传输，而仅传输检测结果的晚期融合又严重丢失了环境上下文信息。此外，车路两端不同的物理视角，使得同一物体在空间分布与视觉表征上存在巨大差异，导致跨端特征难以直接匹配。关键科学问题在于：如何在带宽的约束下，设计一种面向异构特征的协同感知融合框架，既可以保留多模态数据的空间表征信息，又能实现车路段视觉特征的跨域融合。

2) 车路协同系统中大模型的几何认知鸿沟和因果推理问题

现有的多模态大模型虽然具备通用的视觉理解能力，但缺乏处理 V2X 复杂空间映射的先验知识，无法理解路侧视角与自车行驶路径之间的几何相关性。这导致模型面对路侧图像时往往视而不见，既无法精准解析关键物体相对于自车的绝对空间位置，也难以理解复杂的宏观交通态势。这种“视觉-语义”认知的鸿沟，导致大模型难以在感知特征与预测轨迹之间建立稳固的逻辑因果链，使得模型无法构建完整的决策逻辑。拟解决的核心问题是如何建立从高维几何特征到语义的映射机制，能够将空间信息转化为大模型可理解的语义信息，并在大模型推理中构建决策逻辑，实现从感知解析、意图认知到精准轨迹生成的认知闭环，提升模型的轨迹预测精度。

4. 预期研究成果

- 1) 研究并实现面向带宽受限的跨视域协同感知方法
- 2) 研究并实现基于场景语义映射的大模型认知决策与轨迹生成方法
- 3) 完成一套车路协同多模态大模型轨迹预测系统搭建与验证
- 4) 发表 CCF-B 类论文一篇，申请发明专利一项
- 5) 完成硕士研究生学位论文

三、研究方案设计及其可行性分析（包括：研究方法，技术路线，理论分析、计算、实验方法和步骤及其可行性等）（不少于 800 字）

针对本课题拟提出的“面向车路协同的多模态大模型轨迹预测系统”，本研究将遵循“数据构建—感知融合—认知推理—系统验证”的技术路线，具体研究步骤设计如下：

1) 车路协同异构数据预处理与数据集构建

本阶段基于 DAIR-V2X、V2X-Seq 等公开的真实车路协同数据集，构建适用于多模态大模型训练的数据基座。重点针对大模型的训练需求，利用自动化处理技术将场景中的结构化信息、自车状态及物体轨迹转化为自然语言描述，从而构建包含视觉、轨迹与文本的多模态三元组数据集，为后续的语义推理训练奠定数据基础。




图 6：DAIR-V2X 数据集

2) 面向带宽受限的时空动态特征融合网络搭建

本阶段致力于构建“路侧稀疏压缩—车端视觉重构”的非对称感知网络，突破通信瓶颈与视域异构难题。首先在路侧搭建感知网络，利用深度信息引导将二维图像特征转化为三维鸟瞰图空间，并设计特定的地图与感知查询机制，提取关键的静态拓扑与动态物体特征作为高度压缩的矢量化传输数据。在车端设计历史状态交互模块，利用自车过去时刻的轨迹特征构建长时序记忆库，增强感知鲁棒性；其次，通过视觉提示重构模块实现跨域特征的直观融合。将路侧传输的查询向量映射为特殊的视觉提示符号(Visual Prompt Symbols)，并将其叠加在自车感知的 BEV 底图上，实时生成路侧增强的自车鸟瞰图，从而实现跨域特征的融合。最后将图像与自车历史信息输入多模态大模型，利用视觉提示符号作为注意力锚点，辅助大模型生成安全决策。

3) 基于语义驱动的大模型认知推理框架实现

本阶段将构建认知后端，旨在解决大模型空间理解能力不足与决策不可解释的问题。首先开发语义序列化模块，将上阶段提取的数值化几何约束转化为大模型可理解的结构化文本，并结合视觉语言模型提取的天气、拥堵等非结构化场景描述，构建场景文本数据集。随后，选用开源多模态大模型（如 LLaVA 或 Qwen-VL）作为基座，将对齐后的视觉特征与序列化文本共同输入模型，并通过指令微调激活模型的思维链能力，使其能够输出包含感知解析、意图预测及规划决策的完整逻辑链条，实现从感知到认知的闭环推理。

4) 系统集成与多场景验证

本阶段将上述各功能模块集成为完整的端到端系统，并在真实数据集上展开全面测试。实验将分别在不同通信带宽与延迟条件下进行压力测试，以评估系统的鲁棒性。重点针对无保护左转、及远距离拥堵预警等长尾复杂场景进行验证，通过对比单车智能与传统协同方法在 L2 误

差、碰撞率等安全性指标上的表现，综合评估系统的实际效能与应用潜力。

2. 可行性分析

通过对车路协同领域、多模态融合和大模型的调研，本课题所依托的核心技术已在得到了充分验证。在感知融合方向，鸟瞰图(BEV)感知技术已趋于成熟，诸如 BEVFormer、UniAD 等相关工作充分证明了统一空间表征在处理多视角数据时的有效性。同时，基于稀疏查询 (Query-based)的特征交互机制在 DETR 等研究中被证实能在大幅降低计算与传输开销的同时保留关键几何信息，为解决 V2X 带宽受限问题提供了理论范式。在大模型推理方向，多模态大模型在轨迹预测任务中展现出卓越潜力，诸如 DriveVLM 等工作已成功将 VLM 应用于单车自动驾驶的决策规划，并取得了显著效果，证实了思维脸技术路线的可行性。此外，针对异构数据的处理，学术界在域适应(Domain Adaptation)与多模态对齐领域已积累了成熟的算法框架。而在验证环境方面，DAIR-V2X、V2X-Seq 等高质量开源数据集的发布，涵盖了图像、点云、高精地图及协同轨迹标注，为本课题提出的模型训练与算法验证提供了完备的数据支撑与评估基准。

四、本研究课题可能的创新之处（不少于 500 字）

针对本课题拟提出的面向车路协同的多模态大模型轨迹预测系统，其可能的创新之处主要体现在以下两个方面：

1. 面向带宽受限的跨视域协同感知方法

本课题针对现有车路协同（V2X）系统中存在的通信带宽瓶颈与车路视域异构导致的特征融合难题，突破了传统原始数据融合的局限，创新性的提出了一种基于稀疏查询的非对称感知协同机制。不同于传统方法在原始数据层面的暴力拼接或仅传输检测结果的信息截断，本课题创新性地构建了“路侧稀疏矢量查询”与“车端视觉提示重构”的架构。具体而言，创新点在于提出了一种基于稀疏查询的空间特征解耦策略，将路侧海量的多模态数据重构为极低带宽占用的地图拓扑查询与动态感知查询，在不丢失关键几何结构的前提下实现了数据传输量数量级的降低。同时，针对路侧俯视与车端平视的巨大差异问题，本课题首次引入视觉提示重构方法。不再依赖复杂的特征对齐网络，而是将路侧传输的稀疏矢量映射为显式的视觉提示符号，并精准叠加至自车 BEV 底图。这一创新将复杂的跨域特征融合问题转化为大模型的“注意力锚点”问题，使模型能够利用视觉符号直观地补全盲区，显著提升了系统在动态遮挡场景下的风险识别能力。

2. 基于场景语义映射的大模型认知决策与轨迹生成方法

针对 V2X 场景中大模型难以理解路侧几何特征的痛点，我们设计了语义序列化策略，将严苛的数值化几何约束（如复杂的车道拓扑矩阵、毫米级的障碍物坐标）转化为大模型可直接理解的场景文本描述。在训练阶段，这些描述作为特权监督信号，强制引导模型学习视觉提示符号与深层环境语义之间的对应关系。这一设计有效填补了视觉语言模型在精确空间推理上的短板，使其在推理阶段即便不输入场景描述，也能隐式地解构出精准的空间约束与环境态势。在此基础上，本课题引入思维链（Chain-of-Thought, CoT）机制，强制模型在输出轨迹前显式地生成“感知—认知—决策”的逻辑推理链条。这一设计不仅赋予了模型处理长尾复杂场景（如无保护左转、鬼探头）的逻辑泛化能力，更使得最终生成的轨迹具备了符合人类直觉的可解释性。通过将高维语义指令解码为符合动力学约束的连续动作轨迹，显著增强模型在复杂动态场景下的稳定性，提升车路协同自动驾驶的决策和安全能力。

五、研究基础与工作条件（1. 与本项目相关的研究工作积累基础 2. 包括已具备的实验条件，尚缺少的实验条件和拟解决途径）（不少于 500 字）

1. 相关研究工作积累基础：

本人所在实验室在视频多媒体、物联网等领域的人工智能技术研究上已有多年的积累，承接并完成了多个相关项目及课题研究，在该领域拥有较为深厚的技术积累。实验室在自动驾驶感知模型和大语言模型方面已取得了一定的学术成果，为本课题的开展提供了坚实的技术支撑与理论保障。

本人在研究生期间专注于自动驾驶环境感知与协同规划领域的研究，对车路协同（V2X）系统、多传感器融合算法及端到端自动驾驶架构进行了长期的深入调研与文献研读，积累了丰富的理论和技术背景。在技术实践方面，本人已熟练掌握 PyTorch 深度学习框架且对大模型的微调技术及思维链（CoT）推理机制有深入实践，能够利用开源多模态大模型进行跨模态任务的开发，为后续研究提供了必要的技术储备。

2. 已具备的实验条件：

实验室配备了完善的硬件支持，构建了包含高性能本地工作站与 GPU 算力集群的计算环境，全面兼容 PyTorch、TensorFlow 等主流深度学习框架。在算力储备上，实验室部署了多台服务器，其中包括一台搭载 8 张 NVIDIA RTX A6000 专业级显卡的高性能服务器，其具备强大的并行计算能力，能够高效支持大规模人工智能模型的训练与推理任务，为本课题的深入研究提供了坚实的硬件保障。

3. 缺少的实验条件和拟解决途径

在拟开展的面向车路协同的多模态大模型轨迹预测任务中，目前将大语言模型深度融合于车路协同感知与规划的相关工作较少，因此本研究在该方向具有一定的技术创新性。未来，计划深入该领域的最新文献，并基于研究成果，针对现有的任务需求进行具体的实现与优化。在实验过程中，可能会遇到车路协同多模态数据集（包含图像、点云、地图）规模过大以及大模型微调显存开销极高的问题，后续可能需要更强大的 GPU 算力支持，如英伟达 A100 等。必要时，可以考虑通过租用高性能云计算服务来满足大规模参数模型的训练需求。

学位论文工作计划

时间	研究内容	预期效果
2025. 9-2025. 11	初步明确研究方向，查阅文献资料，完成论文的开题工作。	完成开题报告。
2025. 12-2026. 1	研究并实现时空动态特征融合方法，设计空间查询提取与稀疏传输策略。	确定异构特征融合框架，完成代码实现。

2026. 2-2026. 4	开发语义序列化器，将几何约束转化为文本 Token，提取非结构化场景描述。	构建场景化文本数据集，完成认知决策方法的实现。
2026. 5-2026. 8	基于开源大模型微调，设计 CoT 推理策略，实现语义到轨迹的映射。	完成基于大模型推理的认知驱动决策规划方法的初步实现。
2026. 9-2026. 11	实现面向车路协同的多模态大模型轨迹预测系统构建，并进行测试和评估。	完成系统的搭建和评估。
2026. 12-2027. 3	总结研究成果，撰写学位论文，准备答辩材料。	完成论文的撰写和答辩准备。

导师意见

该论文以基于多模态大模型的车路协同车辆轨迹预测方法研究与实现为选题，在学术探索与实际应用中均展现出较高的研究价值。该生对国内外相关课题内容方向进行了充分的调研分析，对车路协同下的轨迹预测方法进行了初步实验验证，并在多模态大模型模型方向积累了一定的研究基础，初步掌握了开展该课题的理论与研究方法。论文拟展开的研究内容设置合理，论文技术路线清晰，预期工作量饱满，目标与预期成果明确。综上，同意开题。

导师（签名）：

日期： 年 月 日

评审结果

经学院组织评审，该生开题评审结果为：

☐通过☐未通过

学院负责人签字（盖章）：

日期： 年 月 日

